Instituto Federal de Educação, Ciência e Tecnologia Sudeste de Minas Gerais - Campus Rio Pomba

Relatório de auditoria de Inteligência Artificial

Projeto: Insulin.A.
Organização: GlicoTech
Discentes: Hérica Martins Lomar, João Miguel Martins Leão, Lara Lopes Coutinho e Wallyson Lopes Pereira
Data: 19 de outubro de 2026

1. **Identificação do sistema**
   A Inteligência Artificial (IA) utilizada no projeto referido, procura realizar uma triagem inicial com usuários que suspeitem de um possível diagnóstico de diabetes mellitus. Os modelos que contribuíram para a realização desse objetivo foram: Random Forest, Regressão Logística e Árvore de Decisão.

2. **Erros encontrados**
   Durante as análises feitas, foram observados erros a depender do modelo. Entre eles, a Árvore de Decisão errou falsos positivos (89 FP contra 13 FN), o Random Forest com falsos negativos (35 FN contra 28 FP), enquanto a Regressão Logística teve resultados em ambos os sentidos (45 FP e 22 FN). Além disso, havia cerca de 264 células preenchidas com medianas, permitindo que as informações relacionadas às respostas pudessem interferir nos resultados do treinamento. Também, foram identificados dados duplicados e entradas inválidas, como: “nan” e o valor de números não inteiros na aba gestações.

3. **Testes de estresse**
   Teste 1: entrada de textos inadequados, como “nan”, que foi aceito pelo sistema.
   Teste 2: entrada de números não inteiros na aba “gestações”. As quais foram aceitas devido a não verificação destes números.
   Teste 3: entrada de valores máximos. Nesse contexto, a Regressão Logística apresentou 100% de probabilidade, enquanto o modelo Random Forest apresentou 51%.

4. **Influência dos atributos**
   Através dos experimentos feitos, foi possível analisar as seguintes alterações:

Característica alterada	Valor inicial	Novo valor	Probabilidade após alteração	Variação
Glicose	120	160	75,3%	+32,0 pontos percentuais
IMC (BMI)	20,8	30	62,9%	+19,6 pontos percentuais
Idade (Age)	48	60	46,9%	+3,7 pontos percentuais
Histórico familiar (DiabetesPedigreeFunction)	0,733	1,2	52,2%	+9,0 pontos percentuais

A missão 3 foi fundamental para a determinação da análise dos resultados.

Dentre as características abordadas, a glicose foi a que mais influenciou a previsão, seguida pelo IMC e o histórico familiar, sendo o fator idade a característica que apresentou menor variação. Todavia, os valores obtidos não comprovam relações de causa e efeito, gerando desse modo, uma discrepância aos valores reais.

5. Melhoria implementada

O problema identificado foi o vazamento de dados (data leakage), causado pelo uso da variável “Outcome”, que realiza previsões de respostas no cálculo das medianas usadas no preenchimento de valores inválidos.
Para corrigir tal problema, seria necessário determinadas implementações, como: separação treino e teste a qual impede que o teste participe da preparação dos dados, tratar os dados em zero inválidos como ausentes os substituindo por NaN (Not a Number), calcular medianas apenas no treino e ajustar StandardScaler somente no treino.

A tabela reproduz os valores informados na análise anterior para 308 amostras. Eles devem ser confirmados executando o código atualizado no mesmo conjunto de dados e com a mesma divisão treino/teste antes de serem apresentados como resultados finais.

Modelo	Acurácia	Precisão	Recall	F1-score
Regressão Logística	78,25%	61,21%	76,34%	67,94%
Árvore de Decisão	66,88%	47,34%	86,02%	61,07%
Random Forest	79,55%	67,44%	62,37%	64,80%

Interpretação das métricas: acurácia é a proporção total de previsões corretas; precisão mostra quantas previsões positivas estavam corretas; recall mostra quantos casos positivos reais foram identificados; F1-score combina precisão e recall. Em saúde, nenhuma métrica isolada é suficiente para avaliar a segurança do sistema.

A principal melhoria proposta para o Insulin.A foi corrigir a preparação dos dados para reduzir o risco de vazamento de informações. As medianas usadas para preencher valores ausentes e os parâmetros de padronização devem ser aprendidos somente no conjunto de treino e depois aplicados ao teste. Isso torna a avaliação metodologicamente mais confiável, embora não garanta, por si só, maior acurácia. O Insulin.A é um projeto acadêmico e não substitui a avaliação ou o diagnóstico de um profissional de saúde.

Exemplo de código para aplicar a melhoria:

```
import numpy as np
from sklearn.preprocessing import StandardScaler

# X_train e X_test já devem estar separados.
colunas_com_zero_invalido = [
    "Glucose", "BloodPressure", "SkinThickness", "Insulin", "BMI"
]

X_train = X_train.copy()
X_test = X_test.copy()

X_train[colunas_com_zero_invalido] = (
    X_train[colunas_com_zero_invalido].replace(0, np.nan)
)
X_test[colunas_com_zero_invalido] = (
    X_test[colunas_com_zero_invalido].replace(0, np.nan)
)

# Aprender medianas somente no treino.
medianas_treino = X_train.median()
X_train = X_train.fillna(medianas_treino)
X_test = X_test.fillna(medianas_treino)

# Ajustar o scaler somente no treino.
scaler = StandardScaler()
X_train = scaler.fit_transform(X_train)
X_test = scaler.transform(X_test)
```

6. Utilização

O Insulin.A. pode ser utilizado como um meio educacional e experimental para estudar e explorar tecnologias diversificadas, quanto ao aprendizado de máquina, comparando modelos, propostas, a fim de compreender melhor como determinadas características influenciam as probabilidades geradas dos resultados. O seu uso deve ser acompanhado pela validação de dados e pela avaliação adequada de desempenho.

Ademais, sua aplicação não pode ser considerada confiável quanto ao diagnóstico preciso do diabetes. Os erros encontrados como o vazamento de dados, as duplicações, a diferença quanto a proporção de indivíduos diabéticos entre o treinamento e o teste, entre outros fatores, comprometem a confiabilidade dos resultados da ferramenta, e por isso, não pode ser avaliado com precisão.